PÁGINA DE INEI

Curso de Capacitación en Fundamentos de Programación para IA Generativa Aplicada a las Ciencias Sociales y la Gestión Pública

Fundamentos de Programación para IA Generativa Aplicada

6 de abril de 2026

ÍNDICE

1. Introducción
2. Objetivo
3. Fuente de datos
4. Estructura de la página web
5. Tipo de código fuente
6. Inspección del código (DevTools)
7. Herramientas utilizadas
8. Proceso de WebScrapping
9. Resultados obtenidos
10. Problemas encontrados
11. Conclusión

Introducción

- El acceso a **microdatos** es fundamental para el análisis económico aplicado, especialmente en estudios de **pobreza, empleo e ingresos**.
- La **Encuesta Nacional de Hogares (ENAHO)**, elaborada por el **INEI**, constituye una de las principales fuentes de información socioeconómica en el Perú.
- Sin embargo, la descarga manual de estas bases desde la plataforma web puede resultar **repetitiva, lenta y propensa a errores**.
- En este contexto, el **web scraping** surge como una herramienta que permite automatizar la extracción de información desde páginas web.
- En este trabajo, se utiliza esta técnica para obtener datos de la **ENAHO** del **INEI**, facilitando su uso en análisis **económicos y sociales**.

OBJETIVO

Objetivo general

Automatizar la **extracción, descarga y procesamiento** de datos de la **ENAHO** desde la plataforma web del **INEI**.

Objetivos específicos

- Simular la interacción de un usuario en la página web mediante **Selenium**
- Identificar y extraer **tablas dinámicas** de resultados
- Descargar archivos de datos en formato **CSV**
- Procesar y estructurar la información en **DataFrames** para su análisis posterior

FUENTE DE DATOS

Plataforma

- Portal de **Microdatos del INEI**

https://proyectos.inei.gob.pe/microdatos/

Base de datos

- **ENAHO** (Encuesta Nacional de Hogares)
- Tema: Condiciones de Vida y Pobreza
- Año: **2024**
- Periodo: **Anual (Ene – Dic)**

Relevancia

- Información a nivel de **hogares e individuos**
- Variables clave: **ingresos, empleo, educación y salud**

ESTRUCTURA DE LA PÁGINA WEB

Funcionamiento general

- La página opera mediante una **interfaz interactiva** basada en formularios. El usuario debe seleccionar distintos filtros para generar los resultados

Componentes principales

- Menú principal de navegación
- Formulario con listas desplegables (dropdowns)
- Tabla dinámica de resultados

Parámetros de selección

- Tipo de encuesta
- Tema
- Año
- Periodo

ESTRUCTURA DE LA PÁGINA WEB

Aspecto clave

La tabla de resultados **no está presente en el HTML inicial**, sino que se genera de forma **dinámica** tras la selección de los parámetros. Esto implica que no es posible aplicar **scraping estático**.

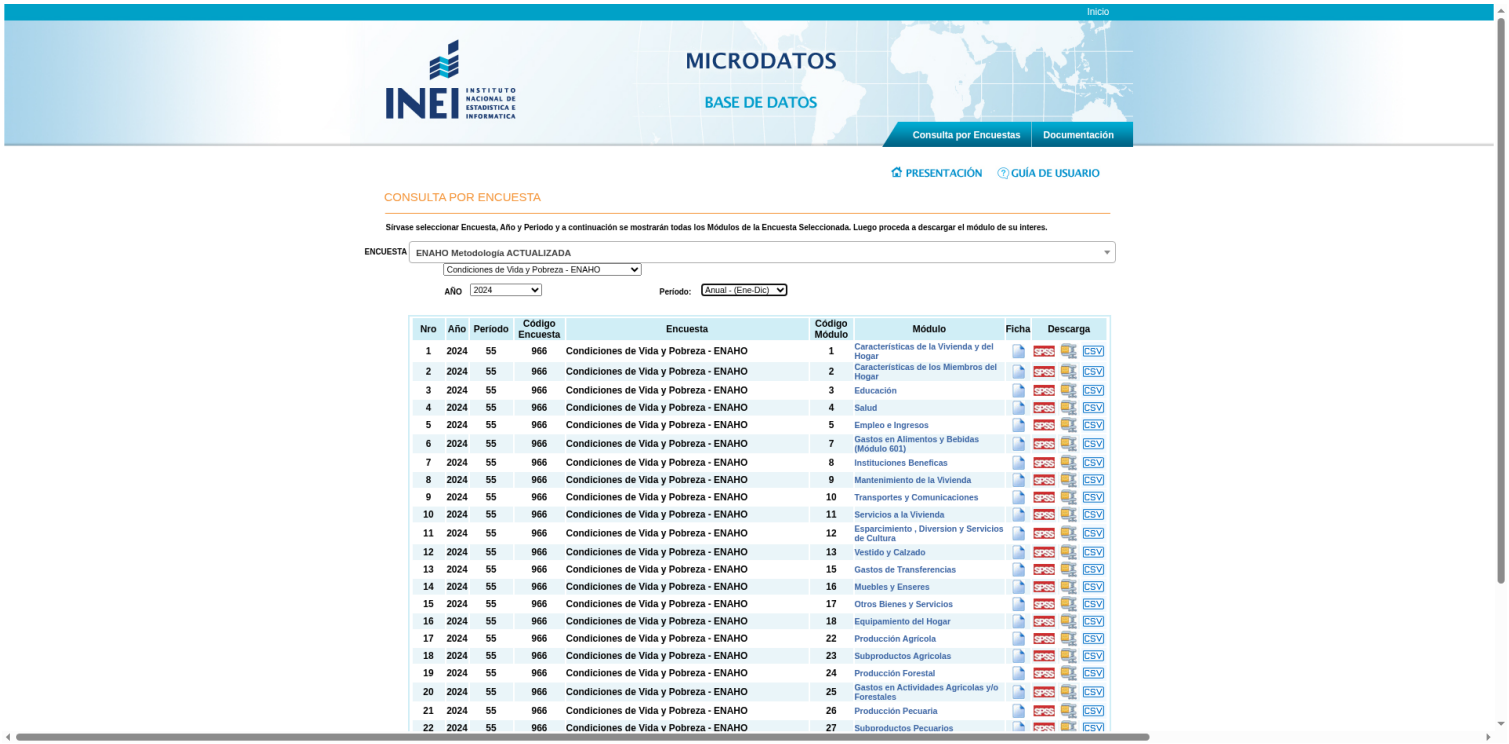

Nro	Año	Período	Código Encuesta	Encuesta	Código Módulo	Módulo	Ficha	Descarga
1	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	1	Características de la Vivienda y del Hogar		CSV
2	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	2	Características de los Miembros del Hogar		CSV
3	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	3	Educación		CSV
4	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	4	Salud		CSV
5	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	5	Empleo e Ingresos		CSV
6	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	7	Gastos en Alimentos y Bebidas (Módulo 601)		CSV
7	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	8	Instituciones Beneficas		CSV
8	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	9	Mantenimiento de la Vivienda		CSV
9	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	10	Transportes y Comunicaciones		CSV
10	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	11	Servicios a la Vivienda		CSV
11	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	12	Esparcimiento , Diversion y Servicios de Cultura		CSV
12	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	13	Vestido y Calzado		CSV
13	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	15	Gastos de Transferencias		CSV
14	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	16	Muebles y Enseres		CSV
15	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	17	Otros Bienes y Servicios		CSV
16	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	18	Equipamiento del Hogar		CSV
17	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	22	Producción Agrícola		CSV
18	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	23	Subproductos Agrícolas		CSV
19	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	24	Producción Forestal		CSV
20	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	25	Gastos en Actividades Agrícolas y/o Forestales		CSV
21	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	26	Producción Pecuaria		CSV
22	2024	55	966	Condiciones de Vida y Pobreza - ENAHO	27	Subproductos Pecuarios		CSV

TIPO DE CÓDIGO FUENTE

Tecnologías utilizadas

- **HTML**: define la estructura de la página (tablas, botones, formularios)
- **CSS**: define el diseño y la presentación visual
- **JavaScript**: permite la generación de contenido dinámico

Implicancia técnica

- La tabla de datos se carga mediante **JavaScript**
- No está disponible en el **HTML inicial**
- Herramientas como **requests** o **BeautifulSoup** no son suficientes

Conclusión

Se requiere el uso de **Selenium** para simular la interacción de un usuario y acceder a la información dinámica.

INSPECCIÓN DEL CÓDIGO

Análisis de la página

- Se utilizó **DevTools** del navegador (F12) para identificar los elementos de interés
- Se analizó el **HTML generado** después de interactuar con la página
- Se verificó que la tabla de resultados se genera de forma **dinámica** mediante **JavaScript**

Hallazgos clave

- La tabla se encuentra dentro del contenedor **divDetalle**
- Estructura identificada:
  - `<table>` → estructura de datos
  - `<tr>` → filas
  - `<td>` → columnas

Estrategia de extracción

- Uso de **XPath** para ubicar la tabla en el DOM
- Uso de **driver.page_source** para capturar el HTML dinámico generado por Selenium

HERRAMIENTAS UTILIZADAS

Entorno de desarrollo

- Uso de **Python** como lenguaje principal
- Ejecución en **Google Colab** con integración a **Google Drive**

Librerías principales

- **Selenium** → automatización de la navegación web
- **WebDriver Manager** → gestión automática del driver
- **Pandas** → manipulación y estructuración de datos
- **Requests** → descarga de archivos
- **Zipfile** → extracción de archivos comprimidos

Configuración clave

- Ejecución del navegador en modo **headless**
- Uso de **WebDriverWait** para gestionar tiempos de carga

PROCESO DE WEBSCRAPPING

1. **Acceso a la página**
   - Apertura del portal del **INEI** mediante **Selenium**
   - Cierre de ventanas emergentes (pop-ups)

2. **Navegación**
   - Acceso a la sección **"Consulta por Encuestas"**

3. **Interacción con el formulario**
   - Selección de filtros:
     - Encuesta: **ENAHO**
     - Tema: **Condiciones de Vida y Pobreza**
     - Año: **2024**
     - Periodo: **Anual**

Resultado

La página genera automáticamente la **tabla de datos**.

PROCESO DE WEBSCRAPPING

4. Extracción de la tabla

- Identificación de la tabla mediante **XPath**
- Recorrido de filas y columnas
- Extracción de enlaces de descarga (**CSV, SPSS, STATA**)

5. Construcción del DataFrame

- Estructuración de datos con **pandas**
- Definición manual de encabezados

6. Descarga de archivos

- Filtrado de módulos relevantes:
  - Salud, Educación, Empleo
  - Vivienda, Hogar
- Descarga desde los enlaces obtenidos

PROCESO DE WEBSCRAPPING

7. Procesamiento de archivos

- Descompresión de archivos **ZIP**
- Extracción de archivos **CSV** específicos

8. Carga y validación de datos

- Lectura de archivos con **pandas**
- Verificación de la estructura de los datos

Resultado final

Base de datos estructurada y lista para **análisis económico**.

RESULTADOS OBTENIDOS

Resultado general

- Se logró **automatizar completamente** el proceso de extracción de datos desde la plataforma del **INEI**
- Se obtuvieron múltiples bases de datos correspondientes a distintos módulos de la **ENAHO**

Resultados específicos

- Descarga automatizada de archivos
- Extracción de datos estructurados
- Creación de **DataFrames** listos para análisis

Conclusión

Los datos obtenidos se encuentran listos para su uso en **análisis econométricos** y estudios aplicados.

PROBLEMAS ENCONTRADOS

Dificultades identificadas

- Uso de **contenido dinámico** mediante JavaScript
- Ausencia de un botón de "consulta" (la tabla se genera automáticamente)
- Dependencia de **tiempos de carga** de la página
- Descarga de archivos en formato **ZIP**
- Variabilidad en los nombres de archivos dentro de los ZIP

Implicancias técnicas

- Necesidad de implementar **WebDriverWait** para sincronizar la carga
- Adaptación del código para procesar archivos comprimidos

Reflexión

Estas dificultades requirieron el uso de herramientas más robustas como **Selenium** y el desarrollo de una lógica adaptable para el procesamiento de datos.

CONCLUSIÓN

Conclusión general

- El **web scraping** permitió automatizar el acceso a microdatos de la **ENAHO** de manera eficiente
- **Selenium** fue fundamental para interactuar con una página web dinámica
- Se desarrolló un proceso completo que incluye:
  - Extracción de datos
  - Descarga de archivos
  - Procesamiento de información

Impacto

- Reducción del tiempo de trabajo
- Minimización de errores manuales
- Mayor **replicabilidad** en investigaciones económicas

Cierre

Este enfoque permite integrar directamente datos oficiales del **INEI** en análisis econométricos de manera automatizada.